



PROJETO INTEGRADOR · FASE 6 · CAPÍTULO 1

FARMTECH VISION


Visão computacional com YOLO e CNN.
De 80 imagens rotuladas a um detector treinado sob medida.

ALUNO

Felipe Yamabe Shimoda de Lima

MATRÍCULA

RM 573344



O CLIENTE QUER VER FUNCIONANDO

A FarmTech Solutions saiu do agronegócio puro e passou a oferecer saúde animal, segurança patrimonial, controle de acesso e visão computacional.

Em visita a um cliente, o time precisa mostrar na prática como um detector de objetos funciona, e o quanto ele acerta.

80

imagens na base

90

objetos rotulados

2,5 min

de treino na GPU

O QUE FOI CONSTRUÍDO

Um detector treinado sob medida para duas classes: maçã e tesoura.

A escolha não é aleatória: os dois objetos são bem diferentes entre si e estão entre as 80 classes da base COCO, o que permite comparar de forma justa com uma YOLO pronta.

A mesma base serve às três abordagens comparadas na Entrega 2.

O QUE VEM A SEGUIR

01**Base de imagens**

80 fotos de licença livre, 40 por classe, divididas em treino, validação e teste.

02**Rotulação**

Caixas desenhadas no Make Sense e exportadas no formato YOLO.

03**Entrega 1**

YOLOv5s treinada em duas simulações: 30 e 60 épocas.

04**Entrega 2**

Comparação com a YOLOv3 pronta do COCO e uma CNN treinada do zero.

05**Decisão**

Qual abordagem entregar ao cliente, e por quê.


A PERGUNTA QUE O TRABALHO RESPONDE

Vale a pena rotular imagens e treinar um modelo próprio, ou uma rede pronta resolve?

01

ENTREGA **1**

YOLOv5 customizada com 30 e 60 épocas



A BASE DE IMAGENS

Amostra do conjunto de treino com as caixas rotuladas no Make Sense



COMO A BASE FOI MONTADA

80 imagens de bases públicas com licença livre, 40 por classe.

Divisão por classe: 32 para treino, 4 para validação e 4 para teste.

90 objetos rotulados, porque 9 imagens trazem mais de um objeto.

A caixa média ocupa 53% da imagem: objetos em primeiro plano, com exemplos menores em cenas externas.

O TRABALHO QUE MAIS RENDEU

Cerca de 40 minutos desenhando caixas no Make Sense, uma ferramenta gratuita que roda no navegador.

- ◆ Projeto do tipo Object Detection, com as classes maca (0) e tesoura (1).
- ◆ Um retângulo justo em volta de cada objeto, nunca polígono.
- ◆ Exportação no formato YOLO: um arquivo de texto por imagem.
- ◆ Cada linha traz classe, centro, largura e altura, normalizados de 0 a 1.
- ◆ Rótulos guardados no Google Drive, junto das imagens.

POR QUE ISSO IMPORTA

As três abordagens da Entrega 2 usaram as mesmas 80 imagens.

O que separou a melhor da pior foi o tipo de rótulo:

caixas por objeto levaram a mAP50 de 0,983;

nenhum rótulo, a 0,784;

apenas a classe da imagem, a 0,625 de acurácia.

TRÊS ETAPAS, UM COMANDO

O treino parte da YOLOv5s já treinada no COCO e ajusta seus pesos às duas classes novas.

01

Treinamento

64 imagens. A rede ajusta os pesos época a época comparando suas previsões com as caixas rotuladas.

02

Validação

8 imagens que a rede nunca usa para aprender. Definem qual época vira o modelo final.

03


Teste

8 imagens inéditas, usadas só no fim, para medir o que o cliente veria.

Parâmetro	Valor	Motivo
Pesos iniciais	yolov5s.pt	Versão small pré-treinada no COCO, rápida e adequada a poucos dados
Resolução	640 pixels	Padrão do YOLOv5, igual ao das imagens preparadas
Épocas	30 e 60	As duas simulações exigidas, bem diferentes entre si
Semente	42	Reprodutibilidade

O QUE MUDA COM O DOBRO DE ÉPOCAS

Curvas de treinamento | 30 x 60 épocas



LEITURA DAS CURVAS

As perdas caem juntas no treino e na validação: não houve memorização.

As métricas de validação sobem e estabilizam perto do teto.

A melhor época foi a 29 de 30 e a 50 de 60: as duas ainda evoluíam no fim.

MAIS ÉPOCAS MELHORAM A CAIXA, NÃO A BUSCA

Métrica na validação	30 épocas	60 épocas
Precisão	0,827	0,910
Recall	0,966	0,999
mAP50	0,953	0,995
mAP50-95	0,600	0,696
Perda de caixa (treino)	0,053	0,024
Tempo de treino	1,8 min	2,5 min

O QUE ISSO SIGNIFICA

O mAP50 já estava quase no teto com 30 épocas e subiu pouco.


Quem ganhou foi o mAP50-95, que exige caixas cada vez mais justas: quase 10 pontos.

O treino mais longo não ensinou a rede a achar mais objetos, ensinou a desenhar caixas melhores.

CUSTO DAS 30 ÉPOCAS EXTRAS

42 segundos a mais na GPU T4.

O QUE O CLIENTE VÊ



AS 8 IMAGENS DE TESTE

Cada par mostra a mesma imagem processada pelo modelo de 30 épocas, à esquerda, e pelo de 60 épocas, à direita.

Nenhuma delas participou do treino nem da escolha do melhor ponto.

A confiança aparece ao lado de cada caixa.

O MODELO MELHOR ACERTA MENOS IMAGENS

No teste, o modelo de 60 épocas tem métricas de detecção melhores e, ainda assim, responde certo em menos imagens. O motivo é o limiar de confiança de 0,25.

Métrica nas 8 imagens de teste	30 épocas	60 épocas
Acurácia por imagem	0,875	0,750
Precisão	0,875	0,900
mAP50	0,881	0,983

LIMIAR É DECISÃO DE NEGÓCIO

Em duas imagens, o modelo de 60 épocas enxerga o objeto, mas com confiança abaixo de 0,25, e a detecção é descartada.

Em contagem de produção, baixar o limiar recupera essas imagens ao custo de alguns alarmes falsos.


Em um sistema que dispara ação cara, o limiar alto é o certo.

O número não muda: a régua muda.

02


ENTREGA 2

YOLO tradicional e CNN treinada do zero



A REDE **PRONTA** ACERTA TUDO, E **ERRA**

Teste da YOLOv3 tradicional (COCO, sem treino)



YOLOv3 DO COCO, SEM TREINO

Acurácia por imagem de 1,000, a melhor das três.

Precisão de 0,732, a pior: marca três maçãs onde existem duas.

Hesita entre knife e scissors com a mesma confiança.

Responde sempre com as 80 classes do COCO, então traz diningtable, bowl e person.

Só funciona enquanto o objeto do cliente estiver nessa lista.

SEM PONTO DE PARTIDA, NÃO APRENDE

Matriz de confusão | CNN no teste

True label	Predicted label	
	Maçã	Tesoura
Maçã	1	3
Tesoura	0	4

CNN TREINADA DO ZERO

Acurácia de 0,625 nas 8 imagens de teste.

Classificou quase tudo como tesoura: recall de 1,00 na tesoura e 0,25 na maçã.


As probabilidades ficaram entre 0,50 e 0,53, praticamente em cima da moeda.

A melhor época foi a terceira de 28: memorizou o treino e parou de generalizar.

Com 64 imagens, o que decide não é a arquitetura, é o ponto de partida.

TRÊS ABORDAGENS, A MESMA RÉGUA

Abordagem	Acurácia	Precisão	mAP50	Treino	CPU	GPU
YOLOv5s customizada, 30 épocas	0,875	0,875	0,881	110 s	263 ms	20 ms
YOLOv5s customizada, 60 épocas	0,750	0,900	0,983	150 s	280 ms	21 ms
YOLOv3 tradicional (COCO)	1,000	0,732	0,784	zero	1.281 ms	não roda
CNN treinada do zero	0,625	0,786	não se aplica	14,5 s	40 ms	30 ms



O QUE OS NÚMEROS **NÃO DIZEM**

01**Jogo fácil**

As duas classes estão no COCO. É o melhor cenário possível para a YOLOv3 e o pior para a comparação: fora dessa lista, ela zera.

02**Métricas diferentes**

A YOLOv3 acerta a classe de todas as imagens e tem a pior precisão, porque inventa maçãs. Para contar, vale a precisão.

03**O hardware inverte**

Em CPU a YOLOv3 leva 1,28 s por imagem, 4,9 vezes a YOLOv5. A rede que não exige treino é a inviável no campo.

04**Rotular pagou**

Mesmas 80 imagens. Caixas por objeto: mAP50 0,983. Sem rótulo: 0,784. Só a classe: 0,625 de acurácia.

RECOMENDAÇÃO À FARMTECH SOLUTIONS

Adotar a YOLOv5 customizada com 60 épocas como base do produto, com o limiar de confiança ajustável por aplicação. A YOLOv3 pronta serve como prova de conceito imediata em objetos comuns. A CNN do zero só passa a fazer sentido com transfer learning e muito mais dado.



ENCERRAMENTO

POUCAS IMAGENS BASTAM PARA COMEÇAR

64 imagens de treino e 2,5 minutos de GPU levaram a mAP50 de 0,995 e recall de 1,000 na validação. O segredo não é volume de dados, é partir de um modelo pré-treinado e rotular bem.

- ◆ Ampliar a base com fotos do ambiente real de operação.
- ◆ Testar com imagens capturadas por ESP32-CAM.
- ◆ Calibrar o limiar de confiança por aplicação.

