PROJETO INTEGRADOR · FASE 6 · CAPÍTULO 1

FARMTECH VISION

Visão computacional com YOLO e CNN.
De 80 imagens rotuladas a um detector treinado sob medida.

ALUNO

Felipe Yamabe Shimoda de Lima

MATRÍCULA

RM 573344

Tecnólogo em Inteligência Artificial · Turma 1TIAOB · São Paulo, 2026

O CLIENTE QUER VER FUNCIONANDO

A FarmTech Solutions saiu do agronegócio puro e passou a oferecer saúde animal, segurança patrimonial, controle de acesso e visão computacional.

Em visita a um cliente, o time precisa mostrar na prática como um detector de objetos funciona, e o quanto ele acerta.

80
imagens na base

90
objetos rotulados

2 min
de treino na GPU

O QUE FOI CONSTRUÍDO

Um detector treinado sob medida para duas classes: maçã e tesoura.

A escolha não é aleatória: os dois objetos são bem diferentes entre si e estão entre as 80 classes da base COCO, o que permite comparar de forma justa com uma YOLO pronta.

A mesma base serve às três abordagens comparadas na Entrega 2.

O QUE VEM A SEGUIR

01

Base de imagens

80 fotos de licença livre, 40 por classe, divididas em treino, validação e teste.

02

Rotulação

Caixas desenhadas no Make Sense e exportadas no formato YOLO.

03

Entrega 1

YOLOv5s treinada em duas simulações: 30 e 60 épocas.

04

Entrega 2

Comparação com a YOLOv3 pronta do COCO e uma CNN treinada do zero.

05

Decisão

Qual abordagem entregar ao cliente, e por quê.

A PERGUNTA QUE O TRABALHO RESPONDE

Vale a pena rotular imagens e treinar um modelo próprio, ou uma rede pronta resolve?

01

ENTREGA 1

YOLOv5 customizada com 30 e 60 épocas

A BASE DE IMAGENS

Amostra do conjunto de treino com as caixas rotuladas no Make Sense



COMO A BASE FOI MONTADA

80 imagens de bases públicas com licença livre, 40 por classe.

Divisão por classe: 32 para treino, 4 para validação e 4 para teste.

90 objetos rotulados, porque 9 imagens trazem mais de um objeto.

A caixa média ocupa 53% da imagem: objetos em primeiro plano, com exemplos menores em cenas externas.

O TRABALHO QUE MAIS RENDEU

Menos de meia hora desenhando caixas no Make Sense, uma ferramenta gratuita que roda no navegador.

- Projeto do tipo Object Detection, com as classes maca (0) e tesoura (1).
- Um retângulo justo em volta de cada objeto, nunca polígono.
- Exportação no formato YOLO: um arquivo de texto por imagem.
- Cada linha traz classe, centro, largura e altura, normalizados de 0 a 1.
- Rótulos guardados no Google Drive, junto das imagens.

POR QUE ISSO IMPORTA

As três abordagens da Entrega 2 usaram as mesmas 80 imagens.

O que separou a melhor da pior foi o tipo de rótulo:

caixas por objeto levaram a mAP50 de 1,000 no teste;

nenhum rótulo, a 0,784;

apenas a classe da imagem, a 0,625 de acurácia.

TRÊS ETAPAS, UM COMANDO

O treino parte da YOLOv5s já treinada no COCO e ajusta seus pesos às duas classes novas.

01

Treinamento

64 imagens. A rede ajusta os pesos época a época comparando suas previsões com as caixas rotuladas.

02

Validação

8 imagens que a rede nunca usa para aprender. Definem qual época vira o modelo final.

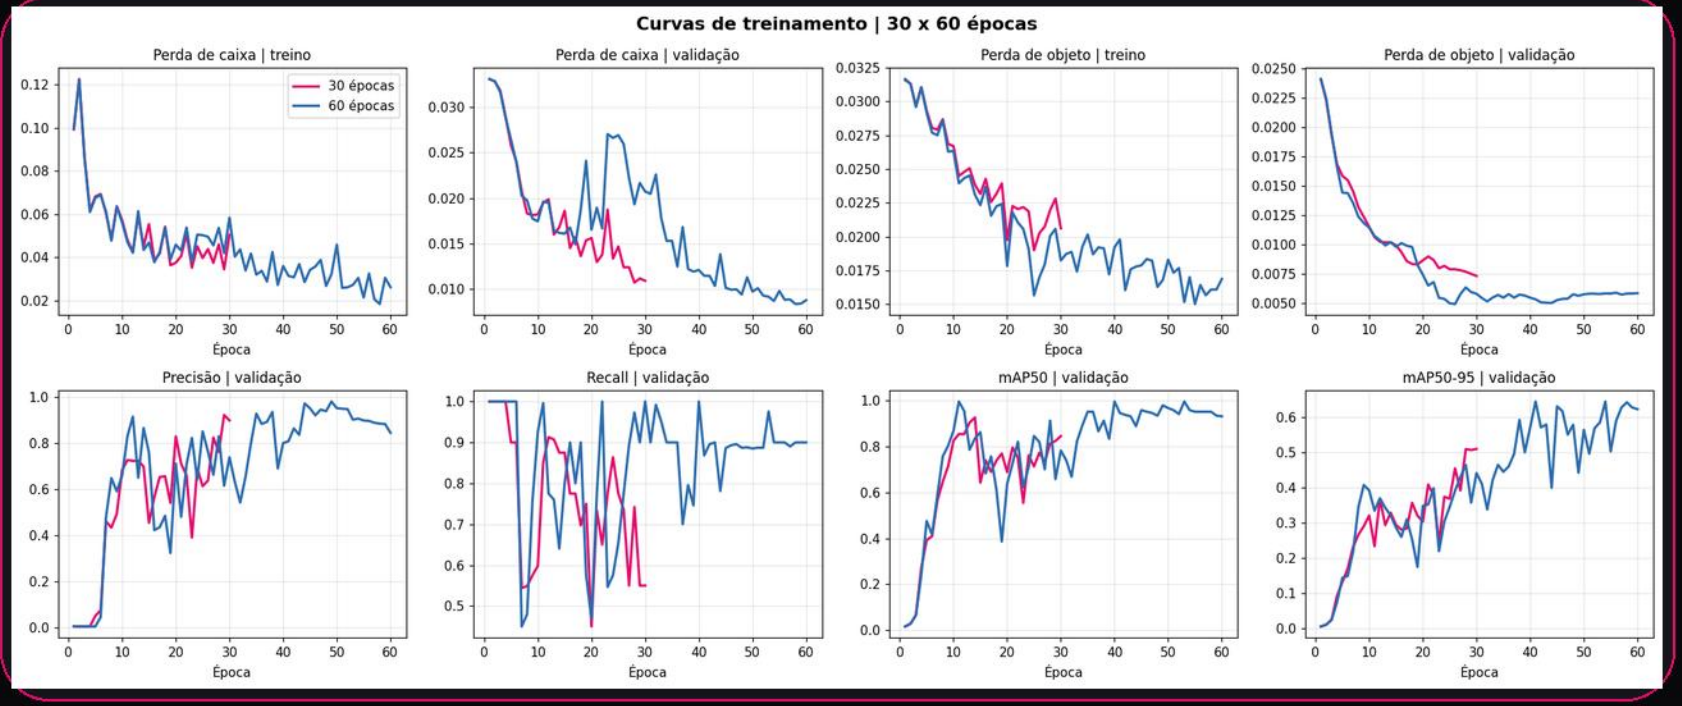
03

Teste

8 imagens inéditas, usadas só no fim, para medir o que o cliente veria.

Parâmetro	Valor	Motivo
Pesos iniciais	yolov5s.pt	Versão small pré-treinada no COCO, rápida e adequada a poucos dados
Resolução	640 pixels	Padrão do YOLOv5, igual ao das imagens preparadas
Épocas	30 e 60	As duas simulações exigidas, bem diferentes entre si
Semente	42	Reprodutibilidade

O QUE MUDA COM O DOBRO DE ÉPOCAS



LEITURA DAS CURVAS

As perdas caem no treino e na validação: não houve memorização prejudicial.

Com 30 épocas, as métricas ainda subiam quando o treino parou: a melhor época foi a última.

Com 60 épocas, o recall se firma perto de 0,90 e a melhor época foi a 54.

30 ÉPOCAS NÃO BASTARAM

Métrica na validação	30 épocas	60 épocas
Precisão	0,899	0,907
Recall	0,550	0,900
mAP50	0,844	0,958
mAP50-95	0,510	0,644
Perda de caixa (treino)	0,050	0,026
Melhor época	30 de 30	54 de 60
Tempo de treino	1,7 min	2,0 min

O QUE ISSO SIGNIFICA

Com 30 épocas, o modelo encontrava só 55% dos objetos da validação.

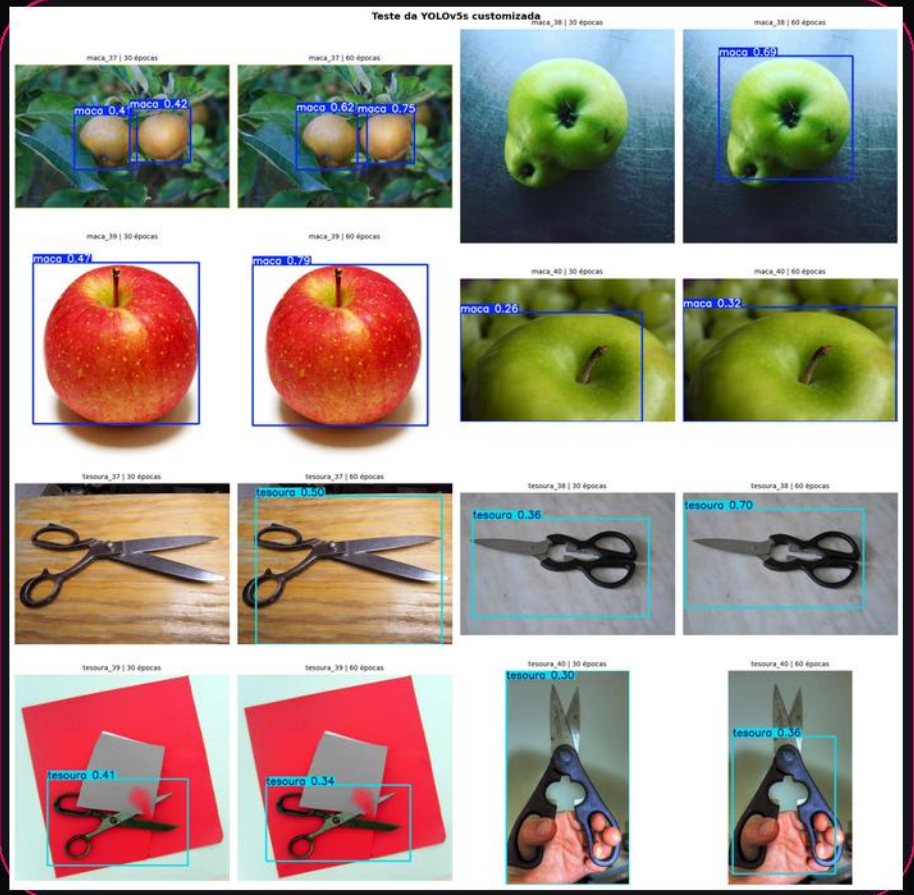
Com 60, o recall foi a 0,90 e o mAP50-95, que exige caixas justas, subiu 13 pontos.

O treino mais longo ensinou a rede a achar mais objetos e a desenhar caixas melhores.

CUSTO DAS 30 ÉPOCAS EXTRAS

21 segundos a mais na GPU T4.

O QUE O CLIENTE VÊ



AS 8 IMAGENS DE TESTE

Cada par mostra a mesma imagem processada pelo modelo de 30 épocas, à esquerda, e pelo de 60 épocas, à direita.

Nenhuma delas participou do treino nem da escolha do melhor ponto.

O de 60 épocas acertou as 8. O de 30 deixou passar maca_38 e tesoura_37.

A confiança aparece ao lado de cada caixa.

O MODELO DE 30 ÉPOCAS VIU, MAS NÃO CONFIOU

No teste, o modelo de 30 épocas encontra todos os objetos (mAP50 de 1,000) e, ainda assim, erra duas imagens. O motivo é o limiar de confiança de 0,25.

Métrica nas 8 imagens de teste	30 épocas	60 épocas
Acurácia por imagem	0,750	1,000
Precisão	1,000	1,000
mAP50	1,000	1,000
Confiança das detecções	0,26 a 0,47	0,32 a 0,79

LIMIAR É DECISÃO DE NEGÓCIO

Em maca_38 e tesoura_37, o modelo de 30 épocas detecta o objeto, mas com confiança abaixo de 0,25, e a detecção é descartada.

Mais treino deixou o modelo mais seguro do que vê.

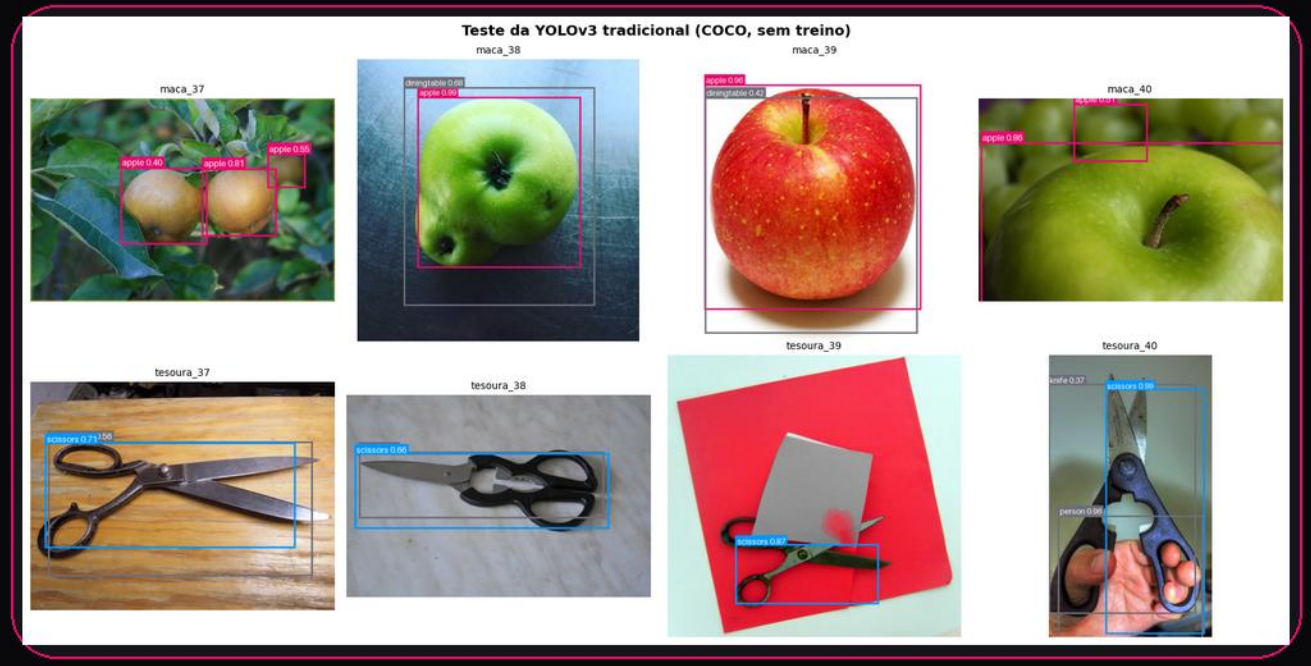
Em contagem de produção, um limiar mais baixo recupera objetos ao custo de alguns alarmes falsos. Em um sistema que dispara ação cara, o limiar alto é o certo.

02

ENTREGA 2

YOLO tradicional e CNN treinada do zero

A REDE PRONTA ACERTA TUDO, E ERRA



YOLOv3 DO COCO, SEM TREINO

Acurácia por imagem de 1,000, empatada com a YOLOv5 de 60 épocas.

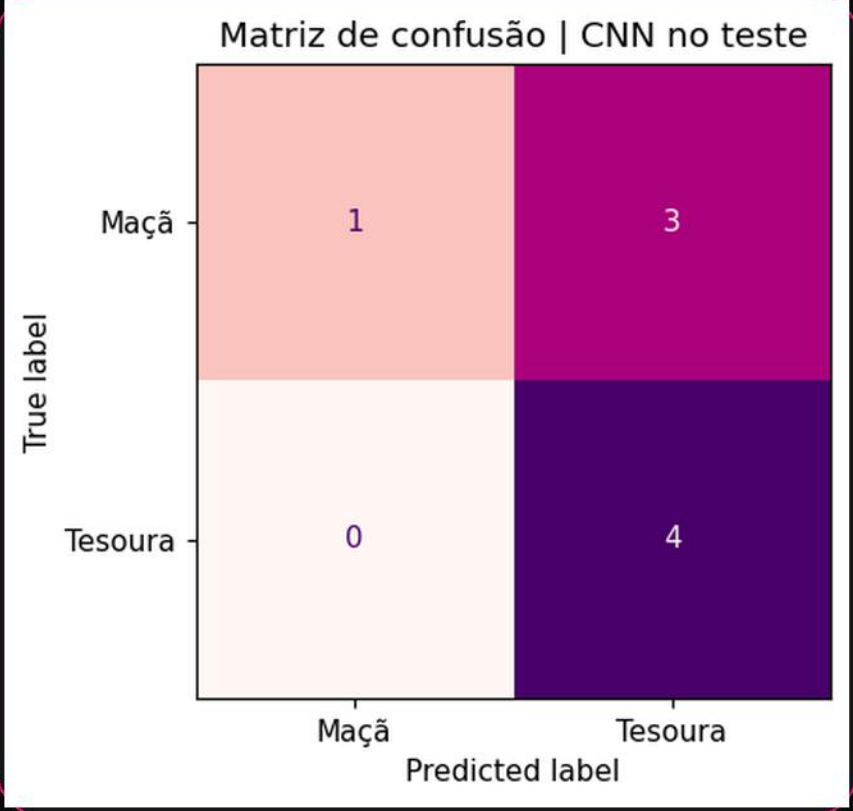
Precisão de 0,732, a pior: marca três maçãs onde existem duas.

Hesita entre knife e scissors com a mesma confiança.

Responde sempre com as 80 classes do COCO, então traz diningtable, bowl e person.

Só funciona enquanto o objeto do cliente estiver nessa lista.

SEM PONTO DE PARTIDA, NÃO APRENDE



CNN TREINADA DO ZERO

Acurácia de 0,625 nas 8 imagens de teste.

Classificou quase tudo como tesoura: recall de 1,00 na tesoura e 0,25 na maçã.

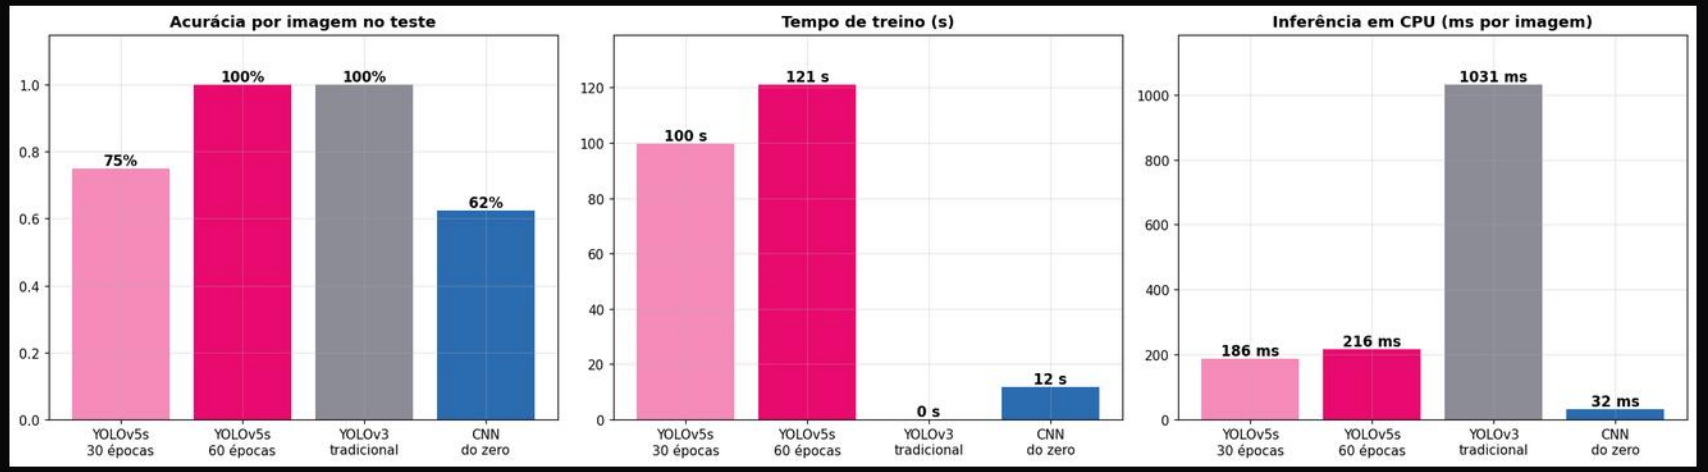
As probabilidades ficaram entre 0,50 e 0,53, praticamente em cima da moeda.

A melhor época foi a terceira de 28: memorizou o treino e parou de generalizar.

Com 64 imagens, o que decide não é a arquitetura, é o ponto de partida.

TRÊS ABORDAGENS, A MESMA RÉGUA

Abordagem	Acurácia	Precisão	mAP50	Treino	CPU	GPU
YOLOv5s customizada, 30 épocas	0,750	1,000	1,000	100 s	186 ms	15 ms
YOLOv5s customizada, 60 épocas	1,000	1,000	1,000	121 s	216 ms	15 ms
YOLOv3 tradicional (COCO)	1,000	0,732	0,784	zero	1.031 ms	não roda
CNN treinada do zero	0,625	0,786	não se aplica	11,8 s	32 ms	23 ms



O QUE OS NÚMEROS NÃO DIZEM

01

Jogo fácil

As duas classes estão no COCO. É o melhor cenário possível para a YOLOv3 e o pior para a comparação: fora dessa lista, ela zera.

02

Métricas diferentes

YOLOv3 e YOLOv5 de 60 épocas acertam as 8 imagens, mas só a YOLOv3 inventa maçãs: precisão de 0,732 contra 1,000.

03

O hardware inverte

Em CPU a YOLOv3 leva 1,03 s por imagem, 4,8 vezes a YOLOv5. A rede que não exige treino é a inviável no campo.

04

Rotular pagou

Mesmas 80 imagens. Caixas por objeto: mAP50 1,000. Sem rótulo: 0,784. Só a classe: 0,625 de acurácia.

RECOMENDAÇÃO À FARMTECH SOLUTIONS

Adotar a YOLOv5 customizada com 60 épocas como base do produto, com o limiar de confiança ajustável por aplicação. A YOLOv3 pronta serve como prova de conceito imediata em objetos comuns. A CNN do zero só passa a fazer sentido com transfer learning e muito mais dado.

ENCERRAMENTO

POUCAS IMAGENS BASTAM PARA COMEÇAR

64 imagens de treino e 2 minutos de GPU levaram a mAP50 de 0,958 na validação e a 8 acertos em 8 imagens de teste. O segredo não é volume de dados, é partir de um modelo pré-treinado e rotular bem.

- Ampliar a base com fotos do ambiente real de operação.
- Testar com imagens capturadas por ESP32-CAM.
- Calibrar o limiar de confiança por aplicação.